Raport Statystyczny nr 1 - Łukasz Stodółka

Zadanie 1

Podstawowe statystyki opisowe (Zad. 1a)

Badana próba liczy **78** uczniów siódmej klasy, w tym **46** chłopców oraz **32** dziewcząt. Poniższa tabela przedstawia podstawowe statystyki opisowe dla zmiennych ilościowych: średniej ocen (**ŚrOc**), ilorazu inteligencji (**IQ**) oraz punktacji w teście psychologicznym (**PH**).

Statystyka	ŚrOc	IQ	PH
Średnia	7.45	108.92	56.96
Mediana	7.83	110.00	59.50
Minimum	0.53	72.00	20.00
Maksimum	10.76	136.00	80.00
Kwartyl dolny (Q1)	6.23	103.00	51.00
Kwartyl górny (Q3)	9.00	118.00	66.00
Wariancja (z próby)	4.41	173.47	154.06
Odchylenie standardowe	2.10	13.17	12.41
Współczynnik zmienności (CV)	28.20%	12.09%	21.79%

Wnioski z obliczonych statystyk (Zad. 1a):
*Na podstawie przedstawionych statystyk można sformułować jedynie ogólne wnioski dotyczące rozkładu badanych zmiennych. Średni poziom **IQ** badanych uczniów wynosi **108.92**, co jest wartością wyższą od średniej populacyjnej przyjmowanej na poziomie 100 punktów. Dla wszystkich trzech zmiennych (**ŚrOc**, **IQ** oraz **PH**) **mediana jest wyższa od średniej**, co może sugerować lekką asymetrię rozkładów i wpływ pojedynczych niższych wartości na obniżenie średniej. Analizując kwartyle można zauważyć, że połowa uczniów osiąga **średnią ocen w przedziale od 6.23 do 9.00**, natomiast dla **IQ** połowa wyników mieści się w przedziale **103.00–118.00**. W przypadku zmiennej **PH** połowa uczniów uzyskała wyniki w przedziale **51.00–66.00**, co wskazuje na umiarkowane zróżnicowanie wyników w tej zmiennej.*

Wizualizacja danych - histogramy i boxploty (Zad. 1b)

Poniższe wykresy przedstawiają rozkłady badanych zmiennych ilościowych oraz pozwalają ocenić ich skupienie, asymetrię i obecność obserwacji odstających.

Zmienna: IQ

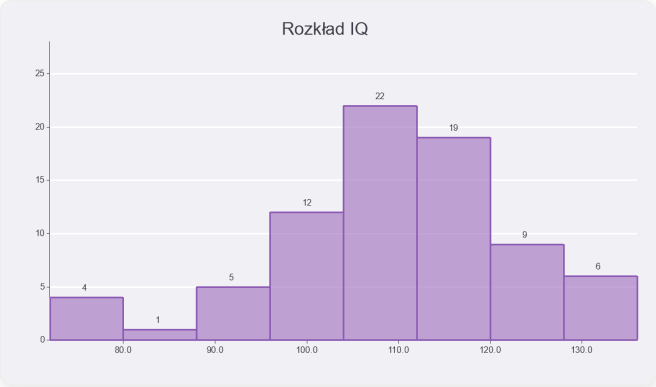

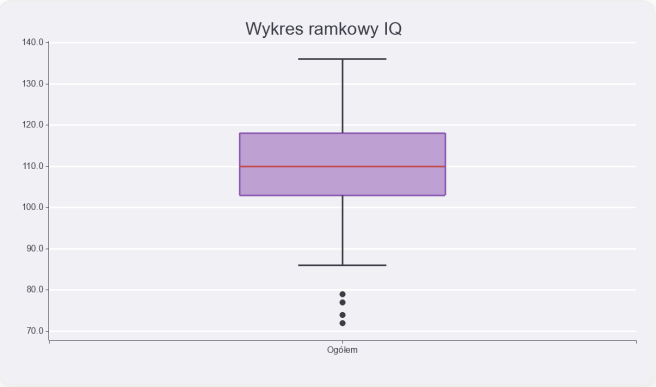

Zmienna: Średnia ocen (ŚrOc)

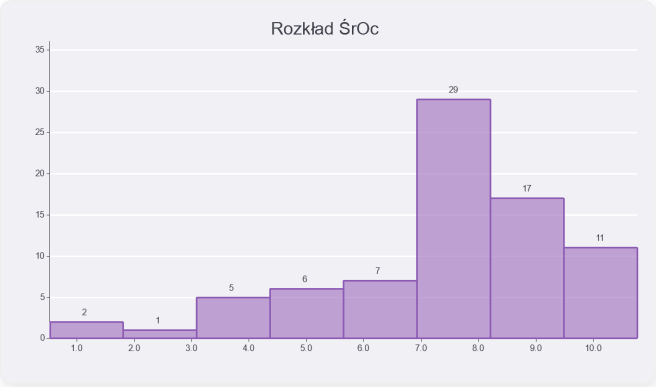

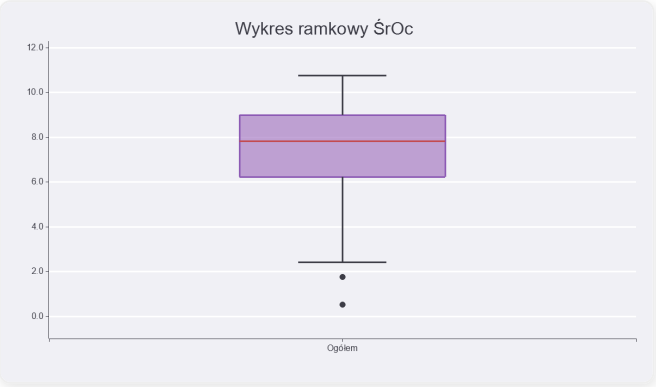

Zmienna: Punktacja psychologiczna (PH)

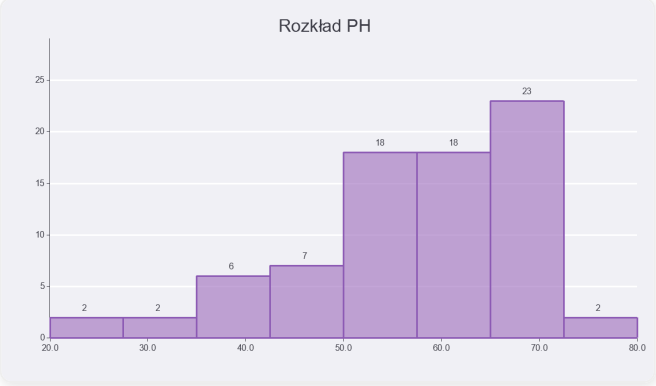

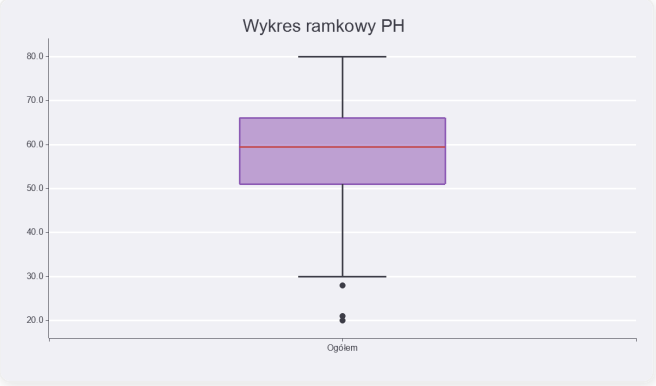

Wnioski na podstawie wykresów (Zad. 1b):
*Na podstawie histogramów można zauważyć, że większość obserwacji dla wszystkich trzech zmiennych skupia się w określonych przedziałach wartości. W przypadku **IQ** największa liczba wyników znajduje się w przedziale około **100–120**, co wskazuje na stosunkowo skoncentrowany rozkład. Histogram dla zmiennej **ŚrOc** pokazuje, że większość uczniów osiąga średnie oceny w przedziale około **6–9**, natomiast niższe wartości pojawiają się znacznie rzadziej. W przypadku zmiennej **PH** największa liczba obserwacji mieści się w przedziale około **50–70 punktów**, co wskazuje na skupienie wyników w tej części skali.*

*Wykresy ramkowe pokazują również obecność **kilku obserwacji odstających**, występujących głównie po stronie niższych wartości. Oznacza to, że w badanej próbie nie ma wyraźnych wartości skrajnie wysokich, pojawiają się natomiast pojedyncze jednostki uzyskujące wyniki niższe od większości grupy. Poza tym większość obserwacji znajduje się w stosunkowo wąskich przedziałach wartości, co sugeruje umiarkowaną spójność badanej próby.*

Porównanie chłopców i dziewcząt (Zad. 1c)

IQ

Statystyka	Chłopcy	Dziewczęta
Średnia	111.35	105.44
Mediana	111.00	106.00
Minimum	77.00	72.00
Maksimum	136.00	132.00
Kwartyl dolny (Q1)	106.00	97.00
Kwartyl górny (Q3)	119.00	114.00
Wariancja	142.85	202.25
Odchylenie standardowe	11.95	14.22
Współczynnik zmienności (CV)	10.73%	13.49%

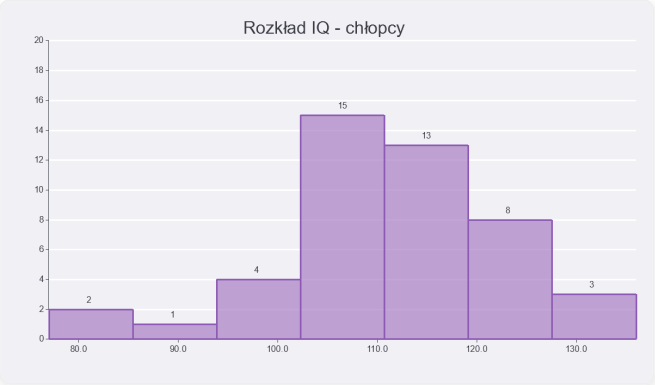

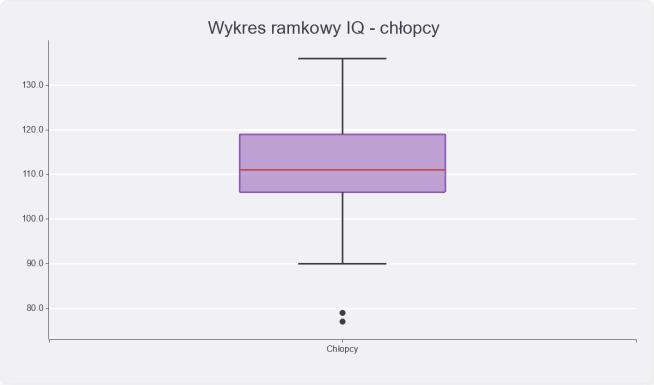

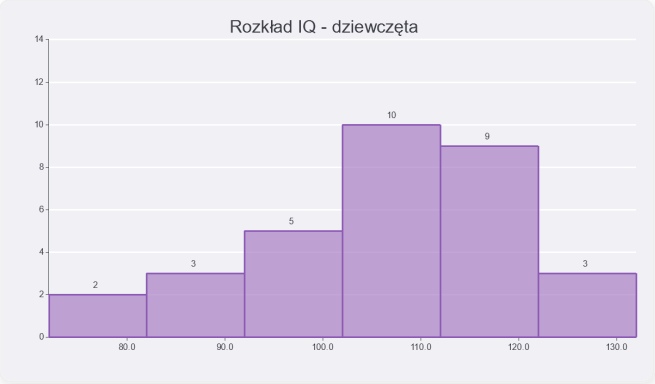

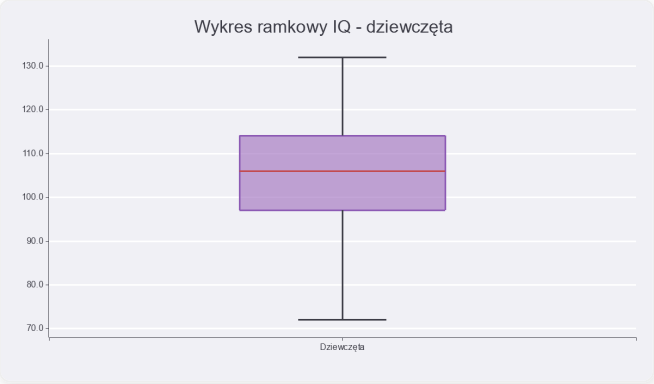

Średnia ocen (ŚrOc)

Statystyka	Chłopcy	Dziewczęta
Średnia	7.28	7.68
Mediana	7.88	7.83
Minimum	0.53	3.41
Maksimum	10.76	10.70
Kwartyl dolny (Q1)	6.17	6.32
Kwartyl górny (Q3)	9.17	8.97
Wariancja	5.50	2.87
Odchylenie standardowe	2.34	1.69
Współczynnik zmienności (CV)	32.20%	22.05%

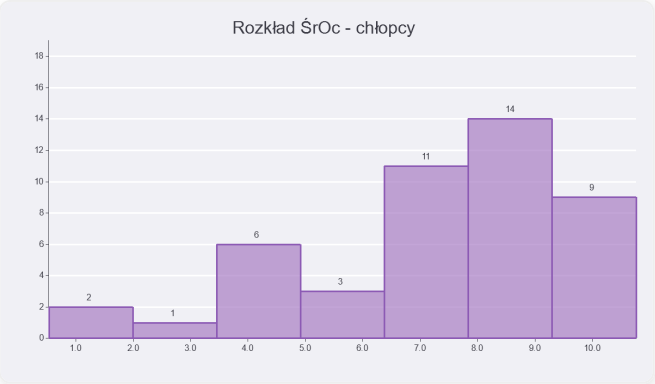

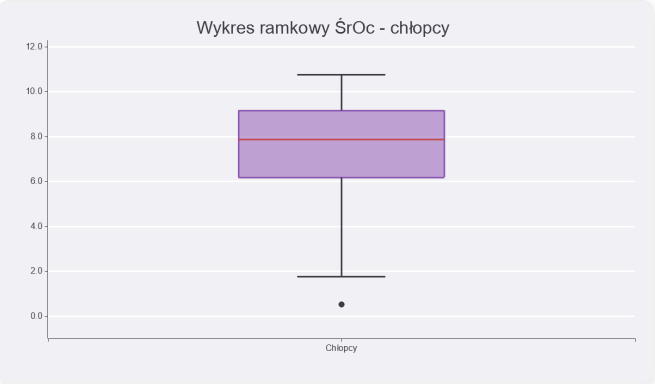

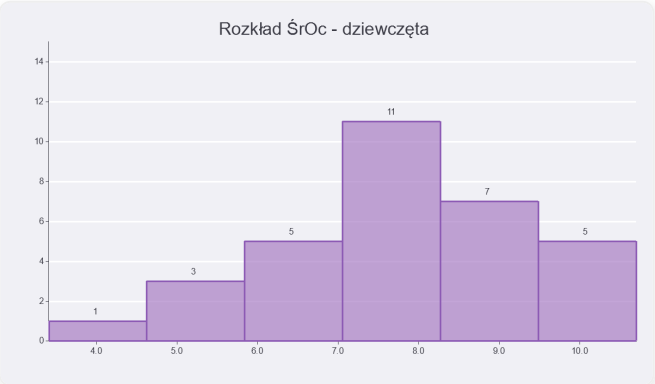

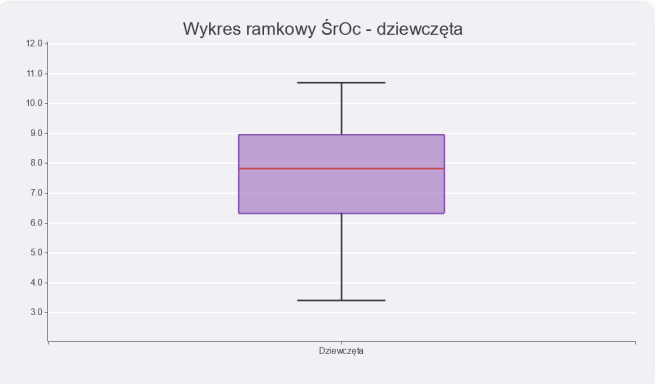

Punktacja psychologiczna (PH)

Statystyka	Chłopcy	Dziewczęta
Średnia	57.85	55.69
Mediana	59.00	60.00
Minimum	20.00	21.00
Maksimum	80.00	72.00
Kwartyl dolny (Q1)	51.00	51.50
Kwartyl górny (Q3)	67.00	64.00
Wariancja	153.55	156.93
Odchylenie standardowe	12.39	12.53
Współczynnik zmienności (CV)	21.42%	22.50%

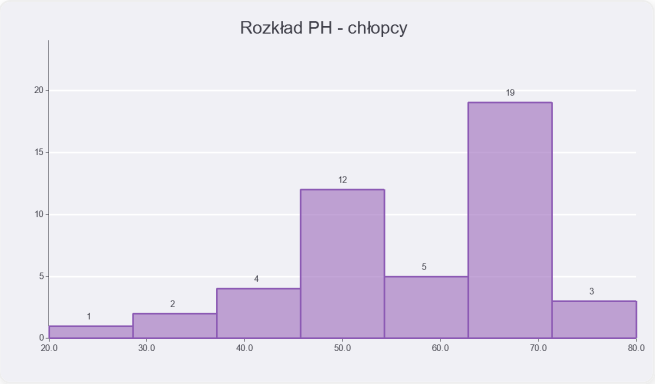

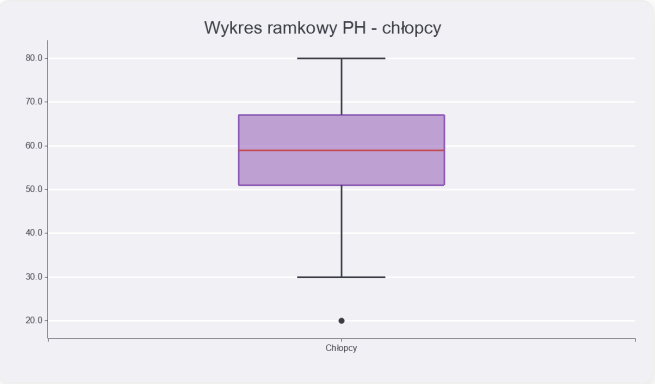

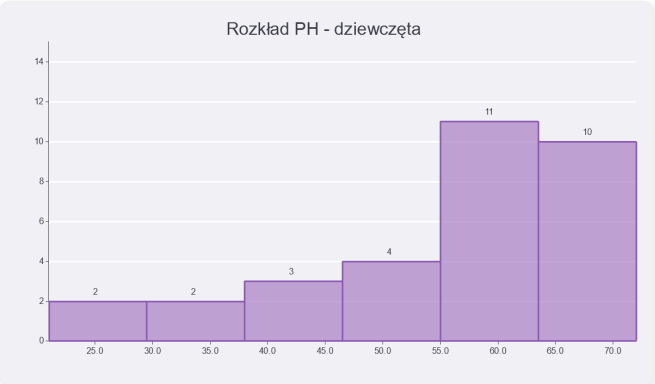

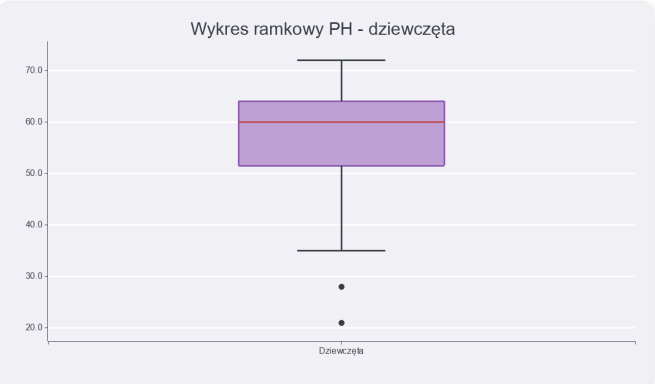

Wykresy porównawcze

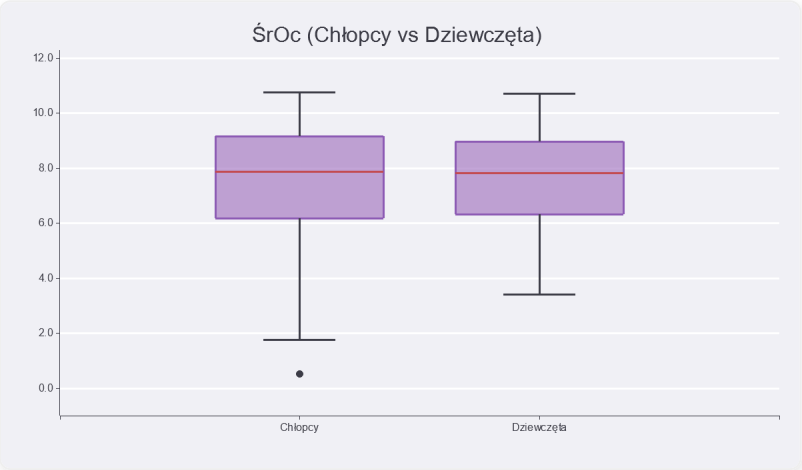

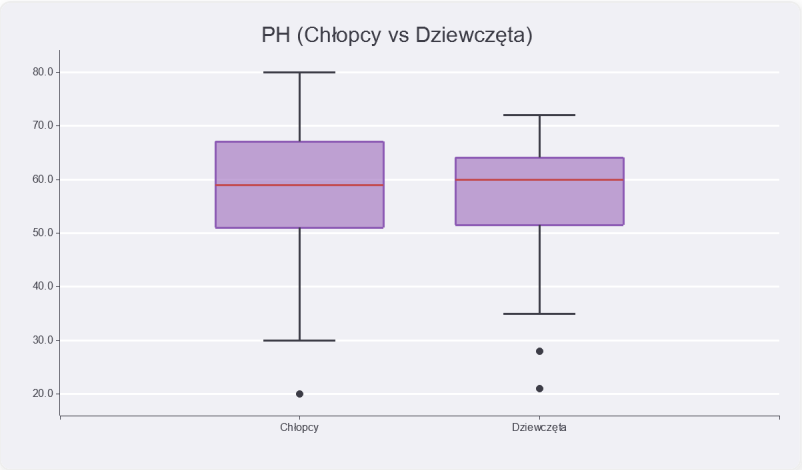

Wnioski z porównania chłopców i dziewcząt (Zad. 1c):
*Na podstawie obliczonych statystyk oraz wykresów można zauważyć kilka różnic między grupą chłopców i dziewcząt. W przypadku **IQ** wyższe wartości średniej i mediany uzyskali **chłopcy** (średnia: **111.35**, mediana: **111.00**) niż **dziewczęta** (średnia: **105.44**, mediana: **106.00**). Jednocześnie u dziewcząt występuje **większe zróżnicowanie wyników IQ**, o czym świadczą wyższe wartości wariancji, odchylenia standardowego oraz współczynnika zmienności. Boxploty pokazują ponadto, że w obu grupach występują pojedyncze niższe obserwacje odstające, przy czym u dziewcząt rozkład jest bardziej rozproszony.*

*W przypadku **średniej ocen (ŚrOc)** sytuacja jest odwrotna - nieco wyższą średnią uzyskały **dziewczęta** (**7.68**) niż **chłopcy** (**7.28**). Mediany obu grup są jednak bardzo zbliżone (**7.83** dla dziewcząt i **7.88** dla chłopców), co oznacza, że typowy poziom ocen jest podobny, lecz w grupie chłopców pojawia się większy rozrzut wyników. Potwierdzają to wyraźnie większe wartości wariancji, odchylenia standardowego i współczynnika zmienności u chłopców. Dodatkowo u chłopców występuje bardzo niska wartość minimalna (**0.53**), która może być obserwacją odstającą i obniżać średnią tej grupy.*

*W przypadku **punktacji psychologicznej (PH)** różnice między grupami są niewielkie. Chłopcy osiągnęli nieco wyższą średnią (**57.85**) niż dziewczęta (**55.69**), natomiast mediany są bardzo podobne (**59.00** i **60.00**). Zmienność wyników PH w obu grupach jest zbliżona, choć minimalnie większa u dziewcząt. Na wykresach ramkowych widać również pojedyncze niższe obserwacje odstające w obu grupach, ale ogólny rozkład punktacji psychologicznej jest podobny.*

*Podsumowując, **chłopcy uzyskali wyższe wyniki IQ**, **dziewczęta osiągnęły nieco wyższą średnią ocen**, natomiast w przypadku **PH różnice są niewielkie**. Największe różnice między grupami dotyczą więc poziomu IQ oraz zmienności wyników szkolnych.*

Wpływ liczby klas na histogram (Zad. 1d)

Zbyt mało klas (liczba klas: 3)

Zbyt mała liczba klas prowadzi do nadmiernego uproszczenia wykresu. Histogram traci szczegóły, przez co rzeczywisty kształt rozkładu staje się słabiej widoczny.

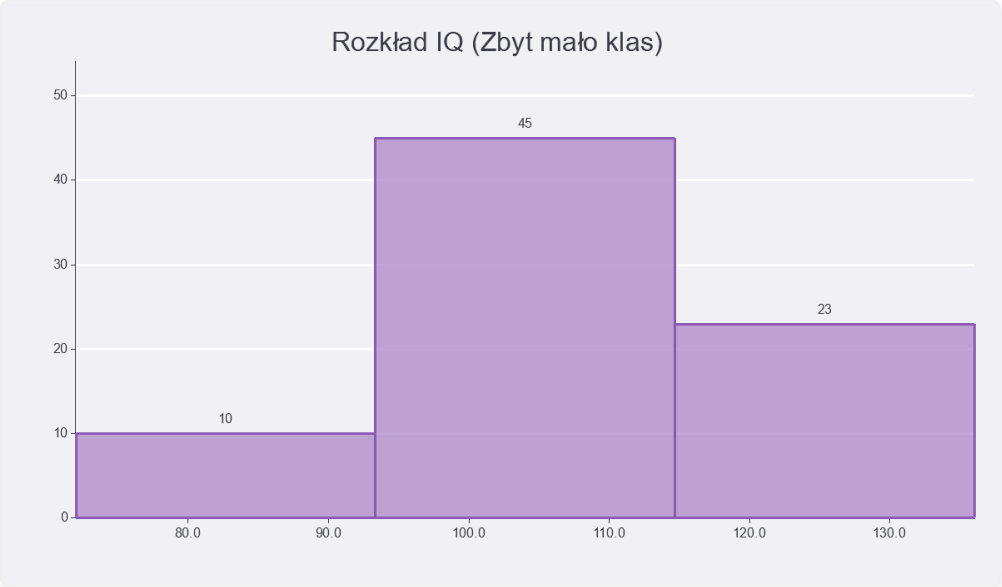

Optymalna liczba klas (liczba klas: 8)

W tej wersji wykorzystano liczbę klas wyznaczoną na podstawie reguły Sturgesa. Taki dobór pozwala zachować równowagę pomiędzy czytelnością wykresu a ilością informacji o rozkładzie danych.

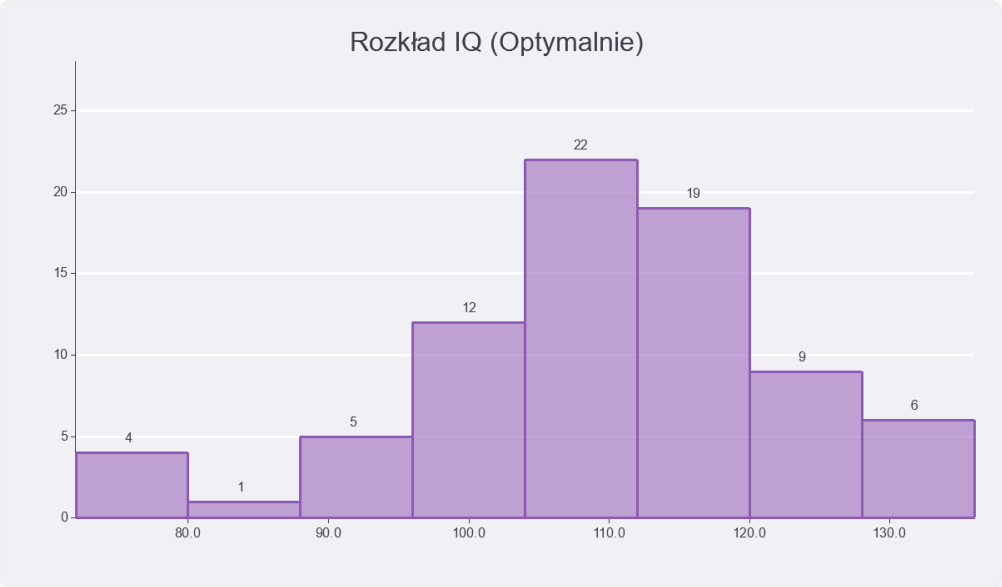

Zbyt dużo klas (liczba klas: 30)

Zbyt duża liczba klas powoduje „poszarpanie” histogramu i zbyt dużą ilość słupków. Na wykresie pojawiają się przypadkowe wahania oraz puste luki, które utrudniają ocenę rzeczywistego rozkładu zmiennej.

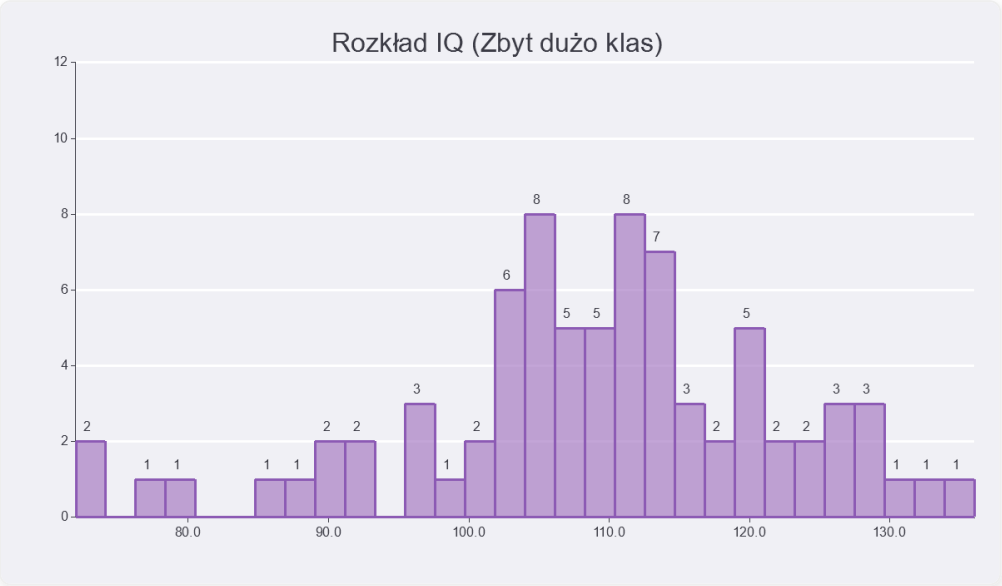

> **Wniosek (Zad. 1d):**
> *Wybór liczby klas ma istotny wpływ na interpretację histogramu. Zbyt mała liczba klas nadmiernie upraszcza obraz danych, natomiast zbyt duża eksponuje przypadkowy szum i utrudnia odczytanie ogólnych tendencji. Spośród przedstawionych wariantów najbardziej użyteczny jest histogram z liczbą klas wyznaczoną według reguły Sturgesa, ponieważ najlepiej zachowuje równowagę między przejrzystością wykresu a dokładnością odwzorowania rozkładu danych.*

Zadanie 2

Struktura zarobków mieszkańców USA w roku 2000 (Zad. 2a)

Badana próba zawiera **55899** obserwacji. Analizie poddano roczne zarobki respondentów w dolarach amerykańskich.

Statystyka	Zarobki
Średnia	37864.61
Mediana	29717.00
Minimum	-24998.00
Maksimum	425510.00
Kwartyl dolny (Q1)	17000.00
Kwartyl górny (Q3)	46505.00
Wariancja (z próby)	1307402975.22
Odchylenie standardowe	36158.03
Współczynnik zmienności (CV)	95.49%

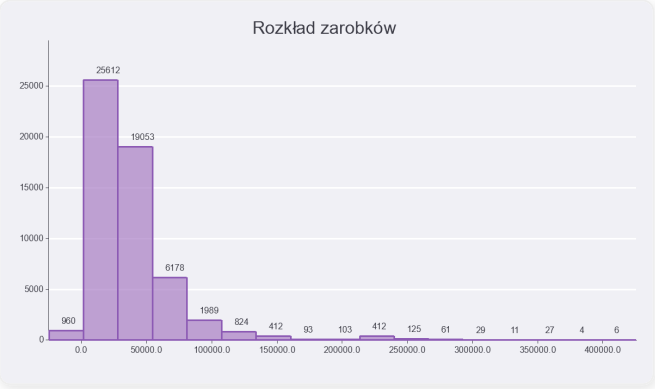

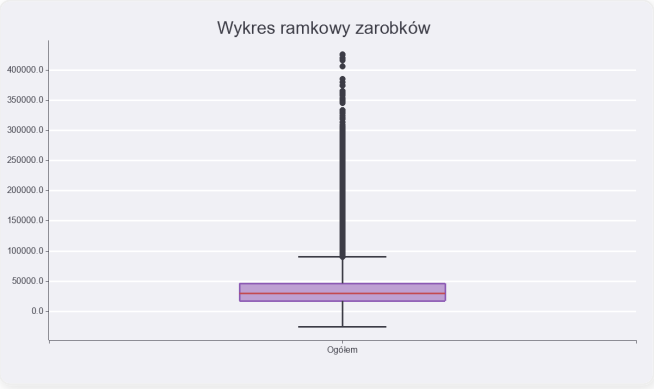

Wnioski (Zad. 2a):

*Rozkład zarobków ma charakter **asymetryczny prawostronnie czyli skośny prawostronnie**, co oznacza, że większość osób osiąga relatywnie niższe dochody, natomiast niewielka grupa uzyskuje bardzo wysokie zarobki. W konsekwencji **średnia jest większa od mediany**, co wskazuje na wpływ wysokich wartości odstających. Histogram ujawnia koncentrację obserwacji w dolnych przedziałach oraz długi ogon po stronie wyższych dochodów. W danych mogą występować również **ujemne wartości dochodów**, które mogą wynikać np. ze strat działalności gospodarczej lub specyfiki sposobu raportowania dochodów.*

Porównanie zarobków w zależności od poziomu wykształcenia (Zad. 2b)

W tej części porównano poziom zarobków w sześciu grupach wykształcenia: od wykształcenia podstawowego do wyższego magisterskiego.

Poziom wykształcenia	Średnia	Mediana	Minimum	Maksimum	Q1	Q3	Odch. std.	CV
Podstawowe	18979.58	15765.00	-9999.00	362302.00	10400.00	23835.00	17137.76	90.30%
Niepełne średnie	21037.41	17011.00	-9999.00	362302.00	10500.00	27000.00	19449.56	92.45%
Średnie	28646.15	24428.00	-9999.00	425510.00	15000.00	36256.00	23905.37	83.45%
Niepełne wyższe	34660.74	29500.00	-9999.00	419304.00	18006.50	43511.50	28429.47	82.02%
Wyższe (licencjat)	49916.61	40072.00	-9999.00	424770.00	25841.00	61250.00	41548.38	83.24%
Wyższe (magister)	70727.34	55350.00	-24998.00	415928.00	36022.50	83522.00	56859.55	80.39%

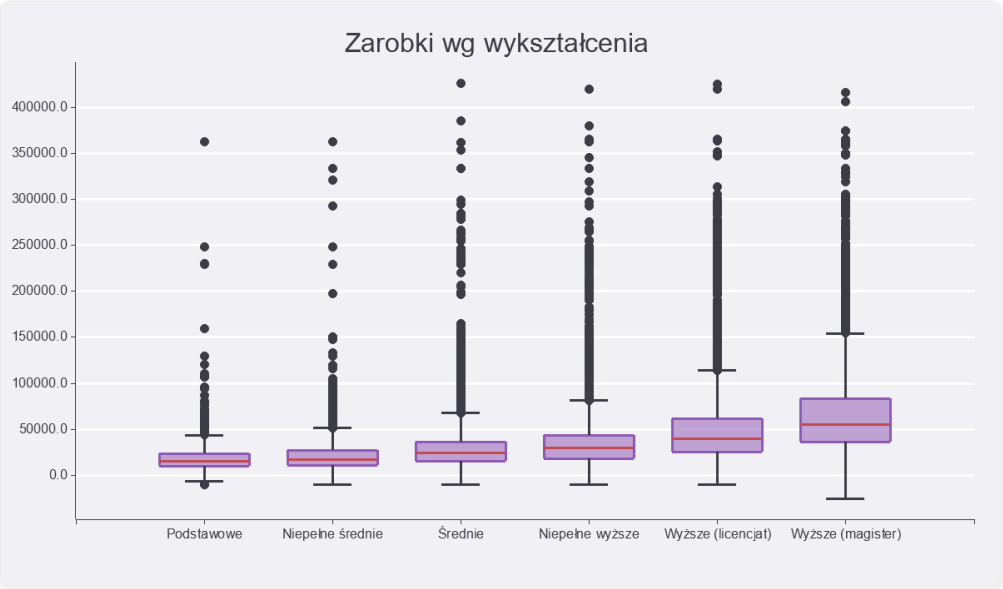

Wnioski (Zad. 2b):
Zarobki wykazują wyraźną zależność od poziomu wykształcenia. Wraz ze wzrostem poziomu edukacji rosną zarówno średnie, jak i mediany dochodów. Osoby z wykształceniem wyższym osiągają istotnie wyższe dochody niż osoby z niższym poziomem wykształcenia. Jednocześnie w każdej grupie widoczne jest znaczne zróżnicowanie, co oznacza, że wykształcenie nie jest jedynym czynnikiem wpływającym na poziom zarobków. W grupach o wyższym wykształceniu częściej występują również ***wartości ekstremalne****, co wskazuje na większe możliwości osiągania bardzo wysokich dochodów.*

Porównanie zarobków kobiet i mężczyzn (Zad. 2c)

Mężczyźni

Statystyka	Zarobki
Średnia	46489.47
Mediana	36000.00
Minimum	-24998.00
Maksimum	425510.00
Kwartyl dolny (Q1)	22146.00
Kwartyl górny (Q3)	55853.00
Wariancja (z próby)	1762121910.83
Odchylenie standardowe	41977.64
Współczynnik zmienności (CV)	90.29%

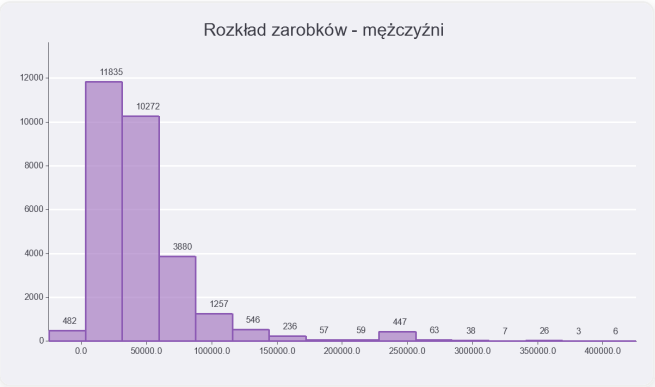

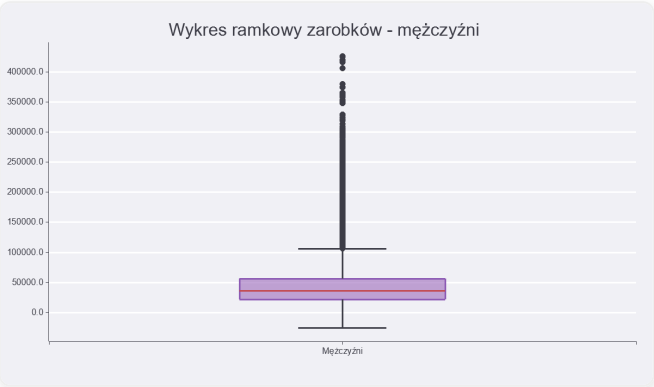

Kobiety

Statystyka	Zarobki
Średnia	28422.35
Mediana	23012.00
Minimum	-9999.00
Maksimum	385068.00
Kwartyl dolny (Q1)	13004.00
Kwartyl górny (Q3)	36200.00
Wariancja (z próby)	639035925.62
Odchylenie standardowe	25279.16
Współczynnik zmienności (CV)	88.94%

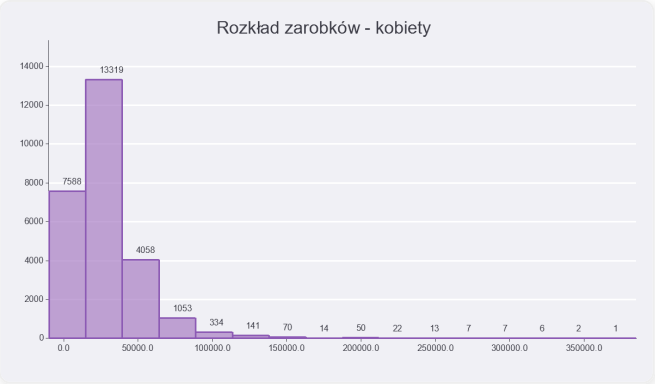

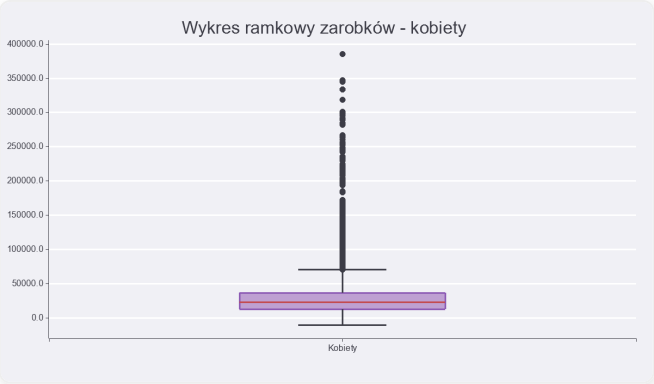

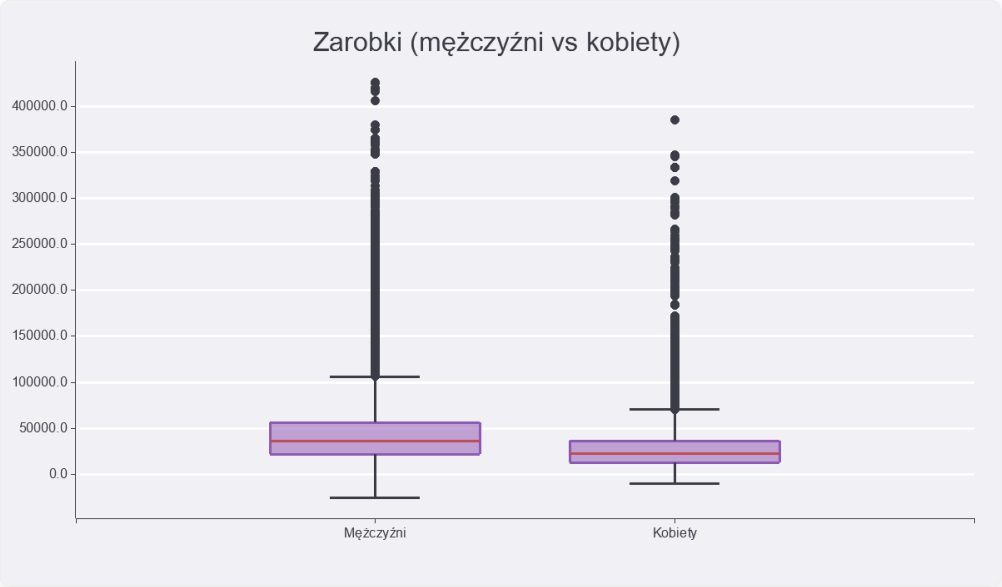

Wnioski (Zad. 2c):
Analiza danych wskazuje na różnice w poziomie zarobków między mężczyznami a kobietami. Jedna z grup osiąga wyższe wartości średnie i mediany, jednak na podstawie tych danych nie można jednoznacznie stwierdzić istnienia związku przyczynowego. Różnice te mogą wynikać z wielu czynników, takich jak wykształcenie, sektor zatrudnienia czy struktura rynku pracy. W związku z tym obserwujemy jedynie ***korelację****, a nie dowód bezpośredniego wpływu płci na poziom dochodów.*

Przeciętny zarobek mieszkańców USA w roku 2000 (Zad. 2d)

W celu wyznaczenia „przeciętnego zarobku" można rozważyć różne miary tendencji centralnej. Najczęściej stosowane są **średnia arytmetyczna** oraz **mediana**.

Miara	Wartość
Średnia	37864.61
Mediana	29717.00

> **Wnioski (Zad. 2d):**
> *Ze względu na silną asymetrię rozkładu zarobków oraz obecność wartości odstających, średnia arytmetyczna nie jest najlepszą miarą „przeciętnego" dochodu. Znacznie lepszą miarą jest **mediana**, ponieważ jest odporna na wpływ skrajnych wartości. Mediana lepiej oddaje typowy poziom dochodu większości populacji, podczas gdy średnia może być zawyżona przez niewielką grupę osób o bardzo wysokich zarobkach.*