# Raport Statystyczny nr 1

Autor: Łukasz Stodółka

## Podstawowe statystyki opisowe (Zad. 1a)

Badana próba liczy **78** uczniów siódmej klasy, w tym **46** chłopców oraz **32** dziewcząt. Poniższa tabela przedstawia podstawowe statystyki opisowe dla zmiennych ilościowych: średniej ocen (**ŚrOc**), ilorazu inteligencji (**IQ**) oraz punktacji w teście psychologicznym (**PH**).

| Statystyka | ŚrOc | IQ | PH |
|---|---|---|---|
| Średnia | 7.45 | 108.92 | 56.96 |
| Mediana | 7.83 | 110.00 | 59.50 |
| Minimum | 0.53 | 72.00 | 20.00 |
| Maksimum | 10.76 | 136.00 | 80.00 |
| Kwartyl dolny (Q1) | 6.23 | 103.00 | 51.00 |
| Kwartyl górny (Q3) | 9.00 | 118.00 | 66.00 |
| Wariancja (z próby) | 4.41 | 173.47 | 154.06 |
| Odchylenie standardowe | 2.10 | 13.17 | 12.41 |
| Współczynnik zmienności (CV) | 28.20% | 12.09% | 21.79% |

**Wniosek:**
*Na podstawie przedstawionych statystyk można sformułować jedynie ogólne wnioski dotyczące rozkładu badanych zmiennych. Średni poziom **IQ** badanych uczniów wynosi **108.92**, co jest wartością wyższą od średniej populacyjnej przyjmowanej na poziomie **100** punktów. Dla wszystkich trzech zmiennych (**ŚrOc**, **IQ** oraz **PH**) **mediana jest wyższa od średniej**, co może sugerować lekką asymetrię rozkładów i wpływ pojedynczych niższych wartości na obniżenie średniej. Analizując kwartyle można zauważyć, że połowa uczniów osiąga średnią ocen w przedziale od **6.23** do **9.00**, natomiast dla **IQ** połowa wyników mieści się w przedziale **103.00–118.00**. W przypadku zmiennej **PH** połowa uczniów uzyskała wyniki w przedziale **51.00–66.00**, co wskazuje na umiarkowane zróżnicowanie wyników w tej zmiennej.*

# Wizualizacja danych - histogramy i boxploty (Zad. 1b)

Poniższe wykresy przedstawiają rozkłady badanych zmiennych ilościowych oraz pozwalają ocenić ich skupienie, asymetrię i obecność obserwacji odstających.

## Zmienna: **IQ**

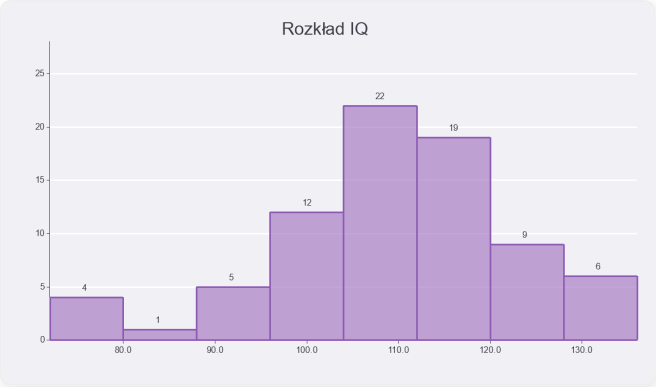


*Rozkład IQ*

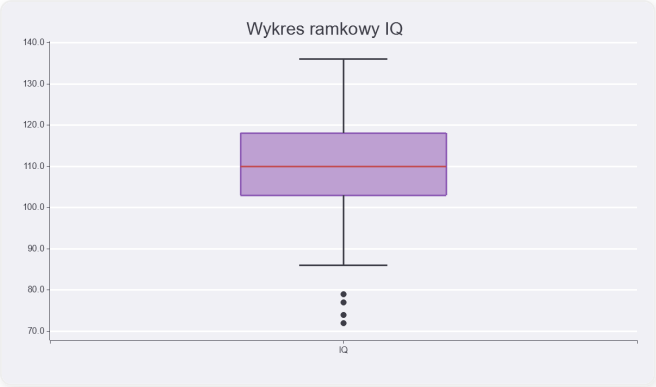


*Wykres ramkowy IQ*

## Zmienna: **Średnia ocen (ŚrOc)**

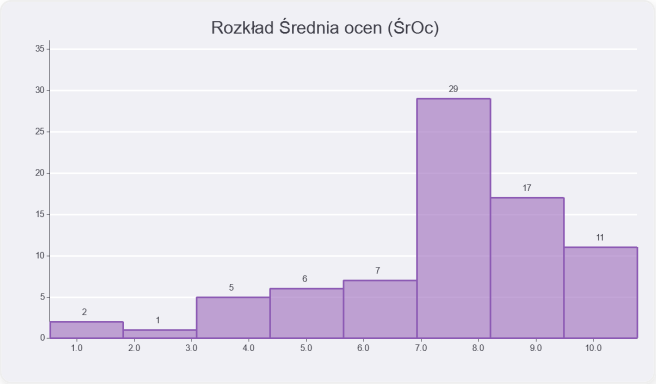


*Rozkład Średnia ocen (ŚrOc)*

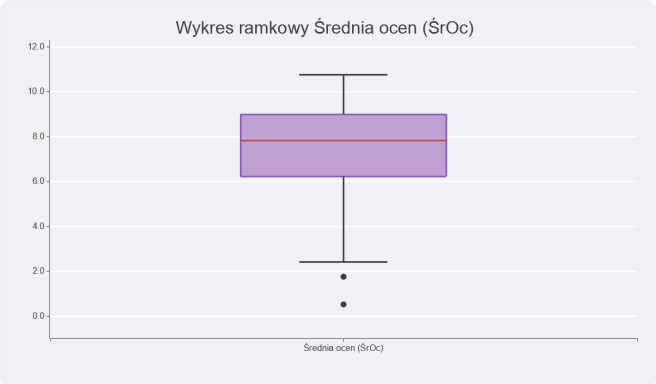


*Wykres ramkowy Średnia ocen (ŚrOc)*

## Zmienna: **Punktacja psychologiczna (PH)**

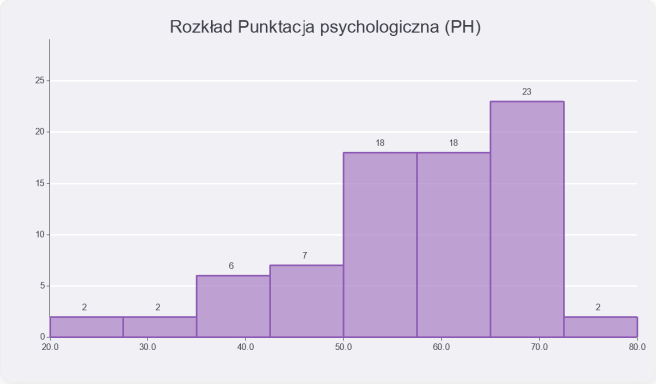


*Rozkład Punktacja psychologiczna (PH)*

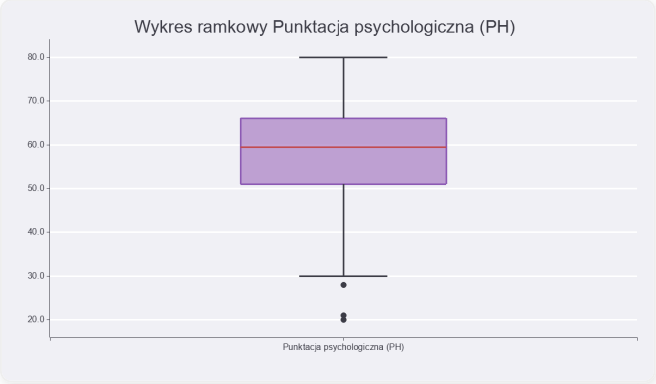


*Wykres ramkowy Punktacja psychologiczna (PH)*

**Wniosek:**
*Na podstawie histogramów można zauważyć, że większość obserwacji dla wszystkich trzech zmiennych skupia się w określonych przedziałach wartości. W przypadku **IQ** największa liczba wyników znajduje się w przedziale około **100–120**, co wskazuje na stosunkowo skoncentrowany rozkład. Histogram dla zmiennej **ŚrOc** pokazuje, że większość uczniów osiąga średnie oceny w przedziale około **6–9**, natomiast niższe wartości pojawiają się znacznie rzadziej. W przypadku zmiennej **PH** największa liczba obserwacji mieści się w przedziale około **50–70** punktów, co wskazuje na skupienie wyników w tej części skali.*

*Wykresy ramkowe pokazują również obecność **kilku obserwacji odstających**, występujących głównie po stronie niższych wartości. Oznacza to, że w badanej próbie nie ma wyraźnych wartości skrajnie wysokich, pojawiają się natomiast pojedyncze jednostki uzyskujące wyniki niższe od większości grupy. Poza tym większość obserwacji znajduje się w stosunkowo wąskich przedziałach wartości, co sugeruje **umiarkowaną spójność badanej próby**.*

# Porównanie chłopców i dziewcząt (Zad. 1c)

## IQ

| Statystyka | Chłopcy | Dziewczęta |
|---|---|---|
| Średnia | 111.35 | 105.44 |
| Mediana | 111.00 | 106.00 |
| Minimum | 77.00 | 72.00 |
| Maksimum | 136.00 | 132.00 |
| Kwartyl dolny (Q1) | 106.00 | 97.00 |
| Kwartyl górny (Q3) | 119.00 | 114.00 |
| Wariancja | 142.85 | 202.25 |
| Odchylenie standardowe | 11.95 | 14.22 |
| Współczynnik zmienności (CV) | 10.73% | 13.49% |

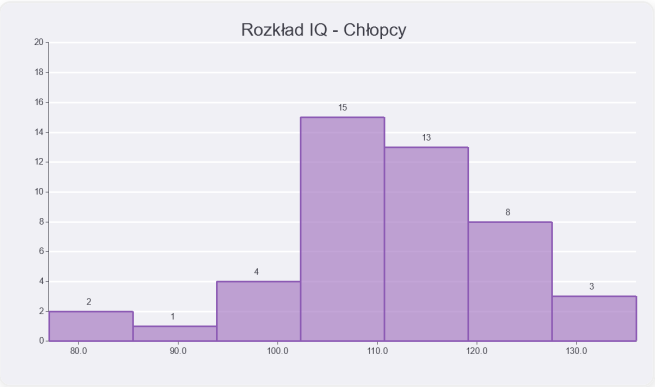


*Rozkład IQ - Chłopcy*

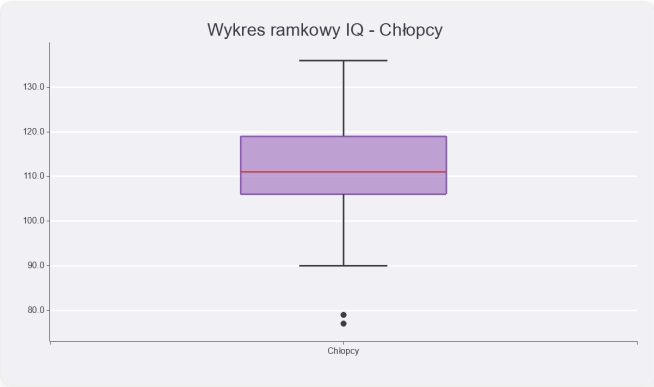


*Wykres ramkowy IQ - Chłopcy*

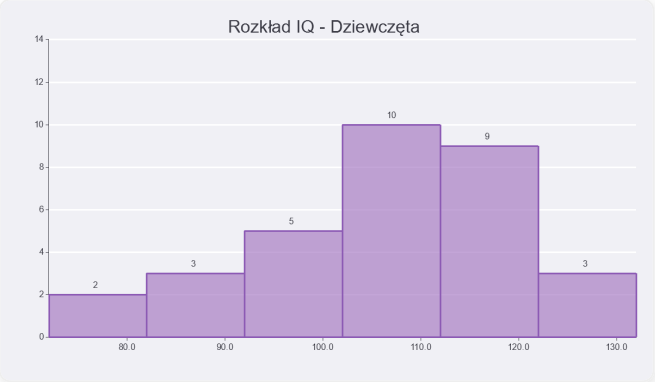


*Rozkład IQ - Dziewczęta*

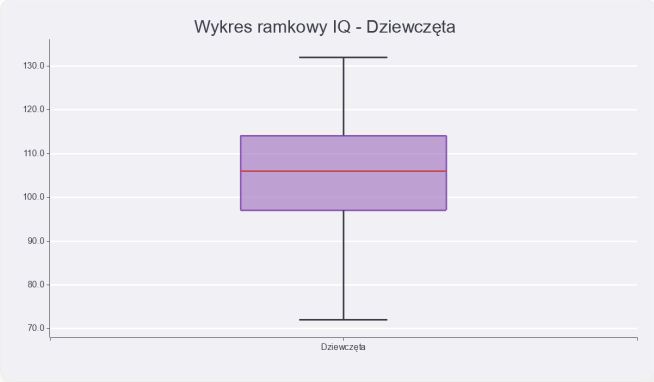


*Wykres ramkowy IQ - Dziewczęta*

## Średnia ocen (ŚrOc)

| Statystyka | Chłopcy | Dziewczęta |
|---|---|---|
| Średnia | 7.28 | 7.68 |
| Mediana | 7.88 | 7.83 |
| Minimum | 0.53 | 3.41 |
| Maksimum | 10.76 | 10.70 |
| Kwartyl dolny (Q1) | 6.17 | 6.32 |
| Kwartyl górny (Q3) | 9.17 | 8.97 |
| Wariancja | 5.50 | 2.87 |
| Odchylenie standardowe | 2.34 | 1.69 |
| Współczynnik zmienności (CV) | 32.20% | 22.05% |

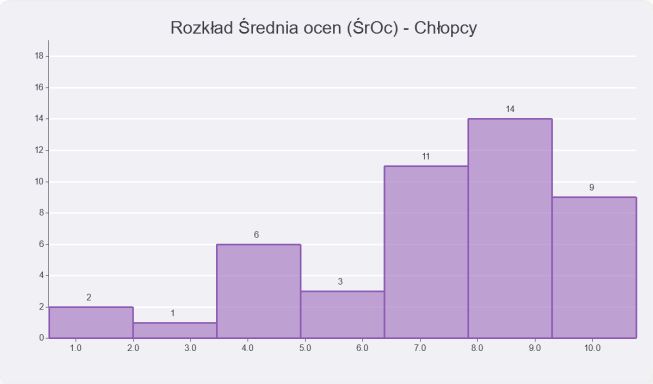


*Rozkład Średnia ocen (ŚrOc) - Chłopcy*

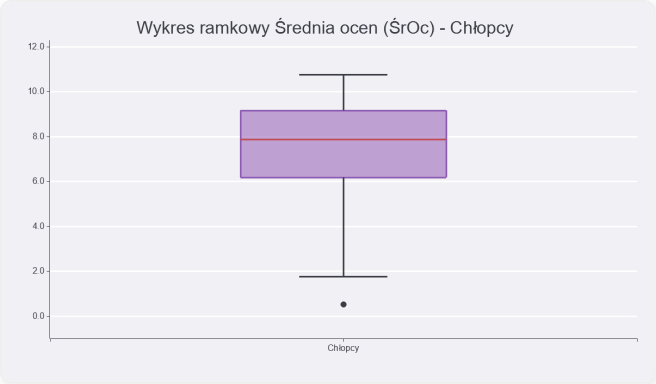


*Wykres ramkowy Średnia ocen (ŚrOc) - Chłopcy*

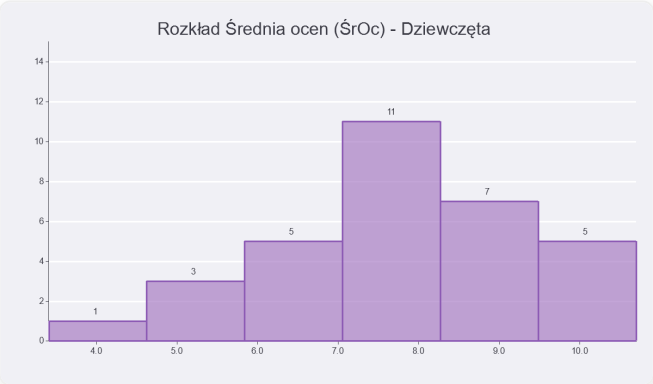


*Rozkład Średnia ocen (ŚrOc) - Dziewczęta*

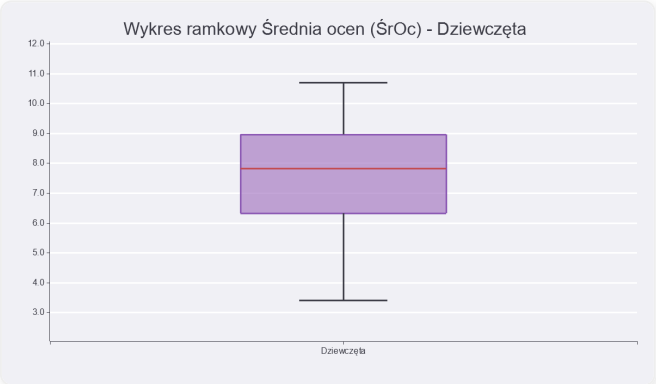


*Wykres ramkowy Średnia ocen (ŚrOc) - Dziewczęta*

## Punktacja psychologiczna (PH)

| Statystyka | Chłopcy | Dziewczęta |
|---|---|---|
| Średnia | 57.85 | 55.69 |
| Mediana | 59.00 | 60.00 |
| Minimum | 20.00 | 21.00 |
| Maksimum | 80.00 | 72.00 |
| Kwartyl dolny (Q1) | 51.00 | 51.50 |
| Kwartyl górny (Q3) | 67.00 | 64.00 |
| Wariancja | 153.55 | 156.93 |
| Odchylenie standardowe | 12.39 | 12.53 |
| Współczynnik zmienności (CV) | 21.42% | 22.50% |

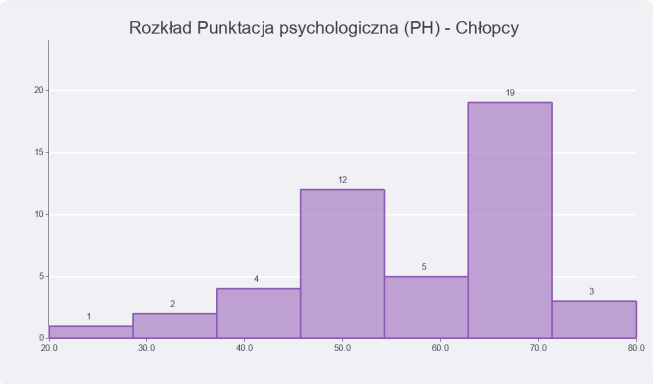


*Rozkład Punktacja psychologiczna (PH) - Chłopcy*

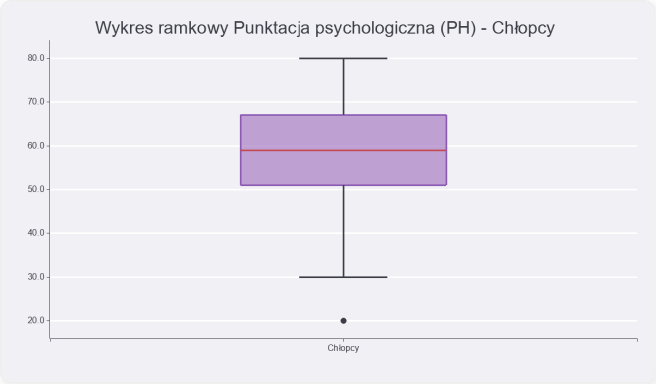


*Wykres ramkowy Punktacja psychologiczna (PH) - Chłopcy*

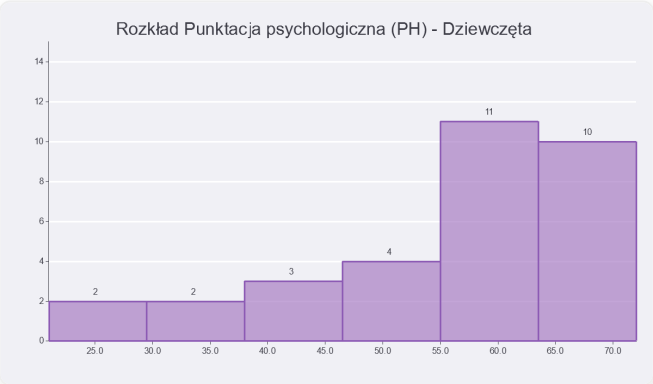


*Rozkład Punktacja psychologiczna (PH) - Dziewczęta*

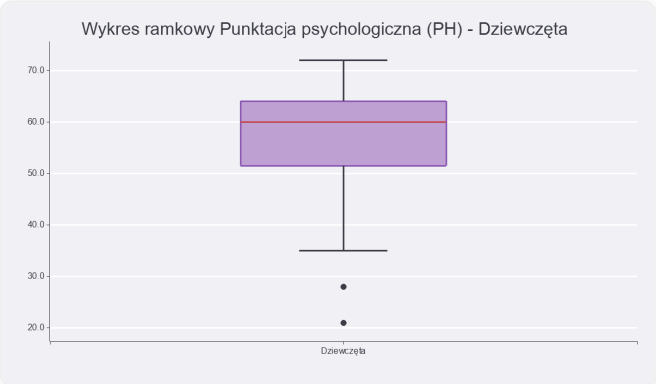


*Wykres ramkowy Punktacja psychologiczna (PH) - Dziewczęta*

## Wykresy porównawcze

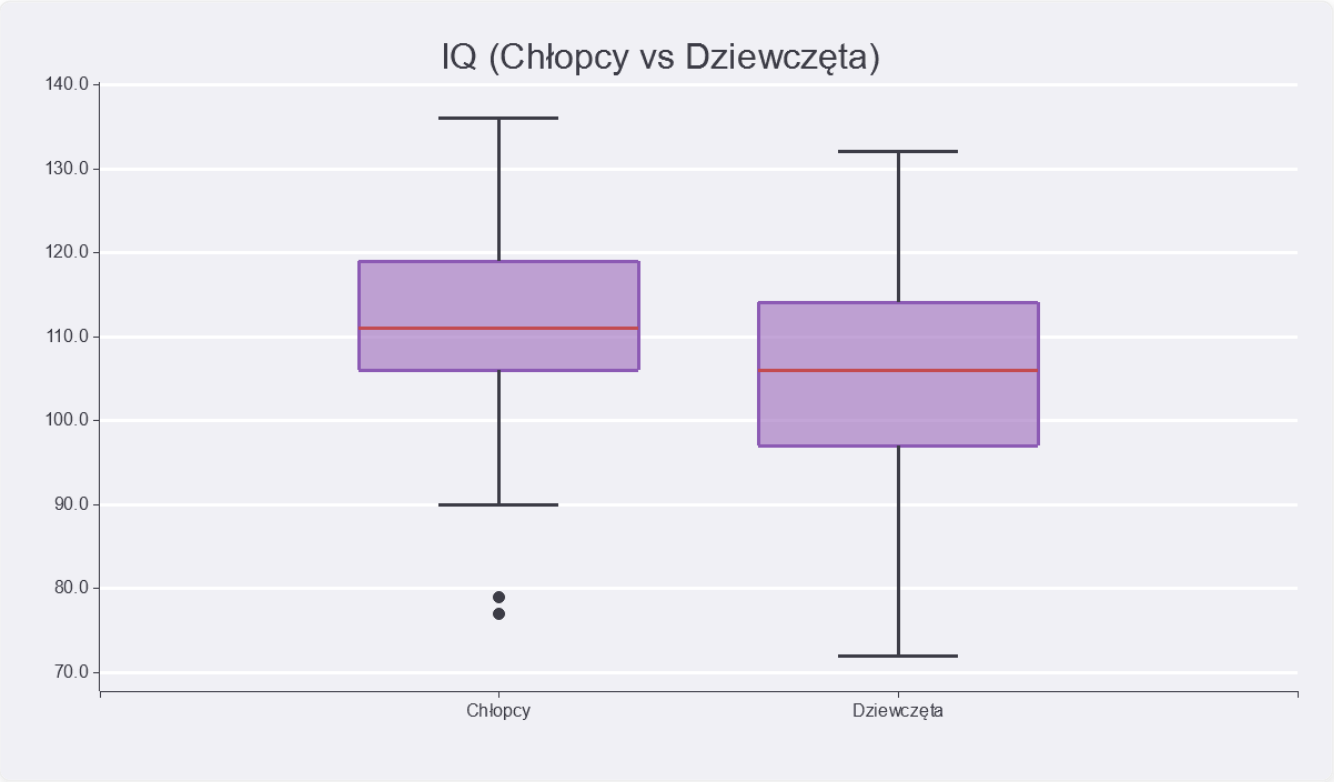


*IQ (Chłopcy vs Dziewczęta)*

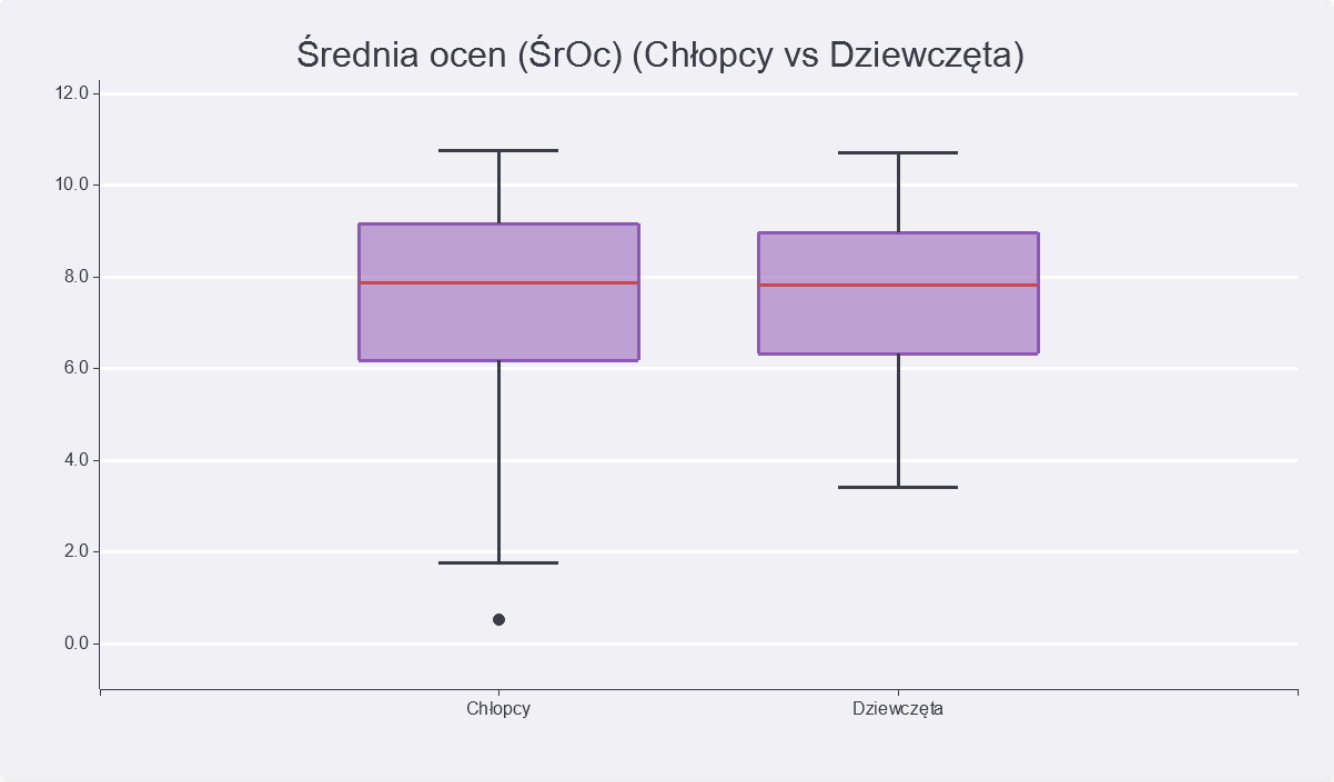


*Średnia ocen (ŚrOc) (Chłopcy vs Dziewczęta)*

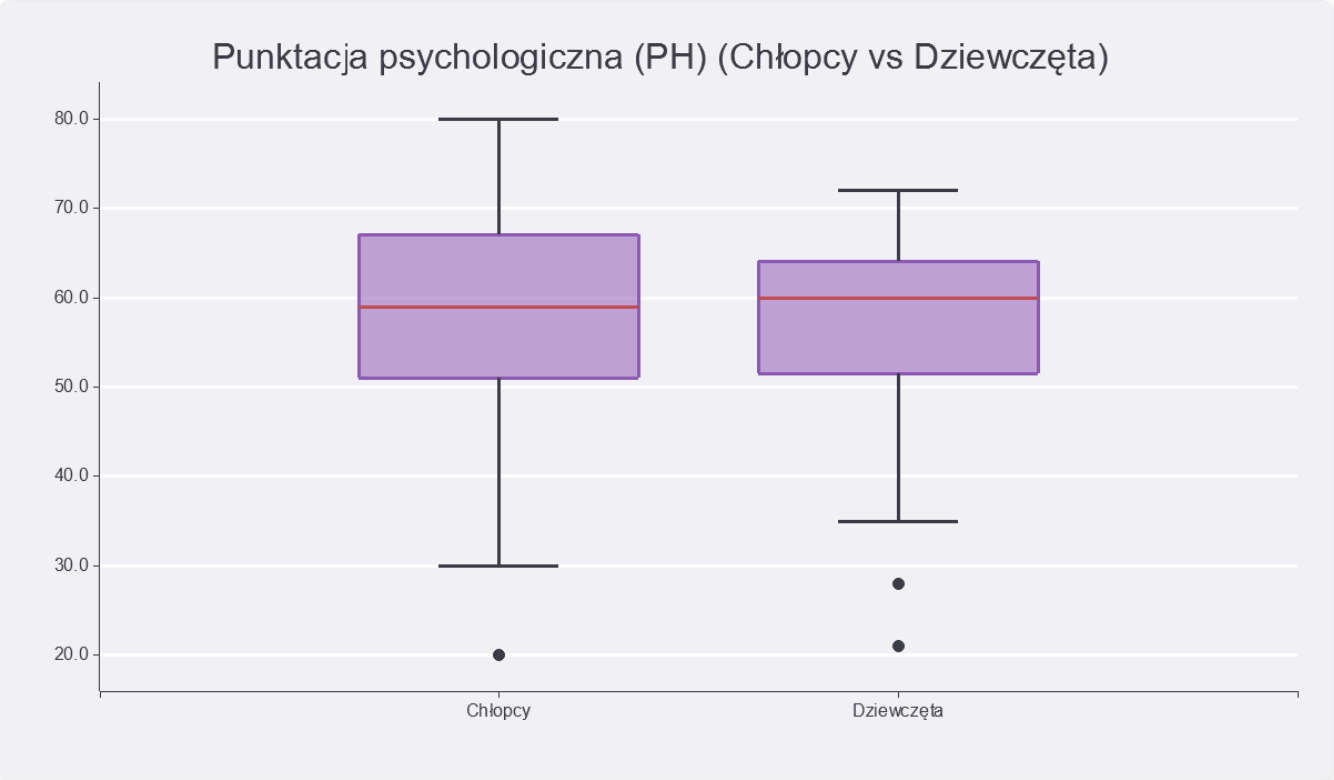


*Punktacja psychologiczna (PH) (Chłopcy vs Dziewczęta)*

**Wniosek:**
*Na podstawie obliczonych statystyk oraz wykresów można zauważyć kilka różnic między grupą **chłopców** i **dziewcząt**. W przypadku **IQ** wyższe wartości średniej i mediany uzyskali **chłopcy** (średnia: **111.35**, mediana: **111.00**) niż **dziewczęta** (średnia: **105.44**, mediana: **106.00**). Jednocześnie u dziewcząt występuje **większe zróżnicowanie wyników IQ**, o czym świadczą wyższe wartości wariancji, odchylenia standardowego oraz współczynnika zmienności. Boxploty pokazują ponadto, że w obu grupach występują **pojedyncze niższe obserwacje odstające**, przy czym u dziewcząt rozkład jest bardziej rozproszony.*

*W przypadku **średniej ocen (ŚrOc)** sytuacja jest odwrotna - nieco wyższą średnią uzyskały **dziewczęta** (**7.68**) niż **chłopcy** (**7.28**). Mediany obu grup są jednak bardzo zbliżone (**7.83** dla dziewcząt i **7.88** dla chłopców), co oznacza, że typowy poziom ocen jest podobny, lecz w grupie chłopców pojawia się **większy rozrzut wyników**. Potwierdzają to wyraźnie większe wartości wariancji, odchylenia standardowego i współczynnika zmienności u chłopców. Dodatkowo u chłopców występuje bardzo niska wartość minimalna (**0.53**), która może być obserwacją odstającą i obniżać średnią tej grupy.*

*W przypadku **punktacji psychologicznej (PH)** różnice między grupami są niewielkie. Chłopcy osiągnęli nieco wyższą średnią (**57.85**) niż dziewczęta (**55.69**), natomiast mediany są bardzo podobne (**59.00** i **60.00**). Zmienność wyników PH w obu grupach jest zbliżona, choć minimalnie większa u dziewcząt. Na wykresach ramkowych widać również pojedyncze niższe obserwacje odstające w obu grupach, ale ogólny rozkład punktacji psychologicznej jest podobny.*

*Podsumowując, **chłopcy uzyskali wyższe wyniki IQ**, **dziewczęta osiągnęły nieco wyższą średnią ocen**, natomiast w przypadku **PH** różnice są niewielkie. Największe różnice między grupami dotyczą więc **poziomu IQ** oraz **zmienności wyników szkolnych**.*

# Wpływ liczby klas na histogram (Zad. 1d)

## Zbyt mało klas (liczba klas: 3)

Zbyt mała liczba klas prowadzi do nadmiernego uproszczenia wykresu. Histogram traci szczegóły, przez co rzeczywisty kształt rozkładu staje się słabiej widoczny.

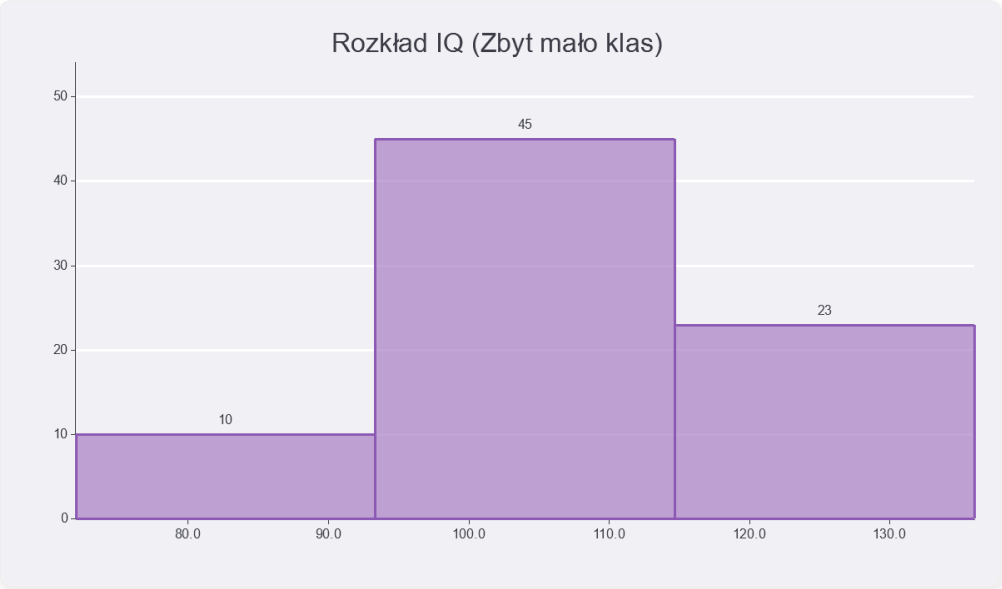


*Rozkład IQ (Zbyt mało klas)*

## Optymalna liczba klas (liczba klas: 8)

W tej wersji wykorzystano liczbę klas wyznaczoną na podstawie **reguły Sturgesa**. Taki dobór pozwala zachować równowagę pomiędzy czytelnością wykresu a ilością informacji o rozkładzie danych.

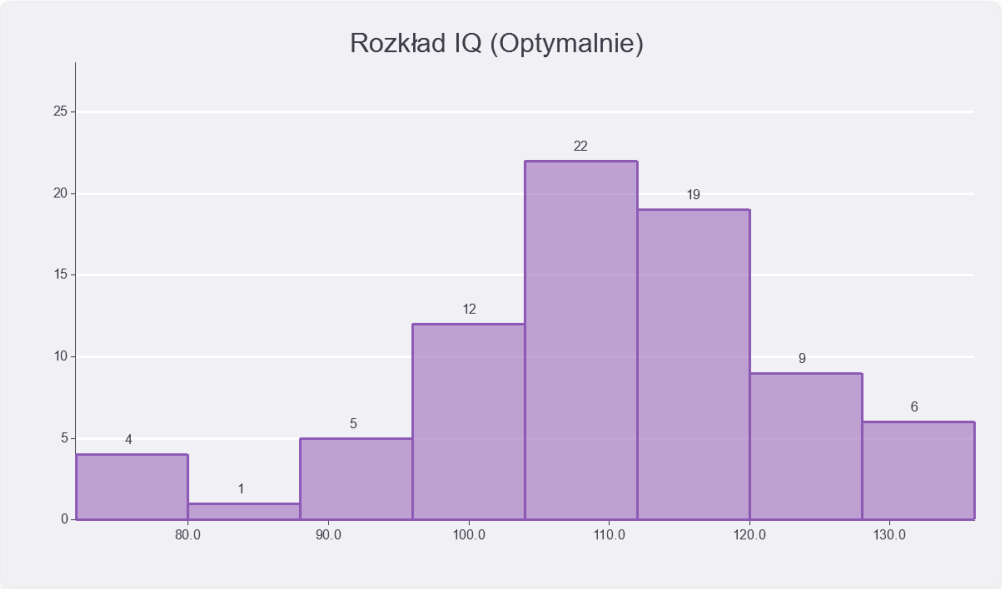


*Rozkład IQ (Optymalnie)*

### Zbyt dużo klas (liczba klas: 30)

Zbyt duża liczba klas powoduje „poszarpanie” histogramu i zbyt dużą ilość słupków. Na wykresie pojawiają się przypadkowe wahania oraz puste luki, które utrudniają ocenę rzeczywistego rozkładu zmiennej.

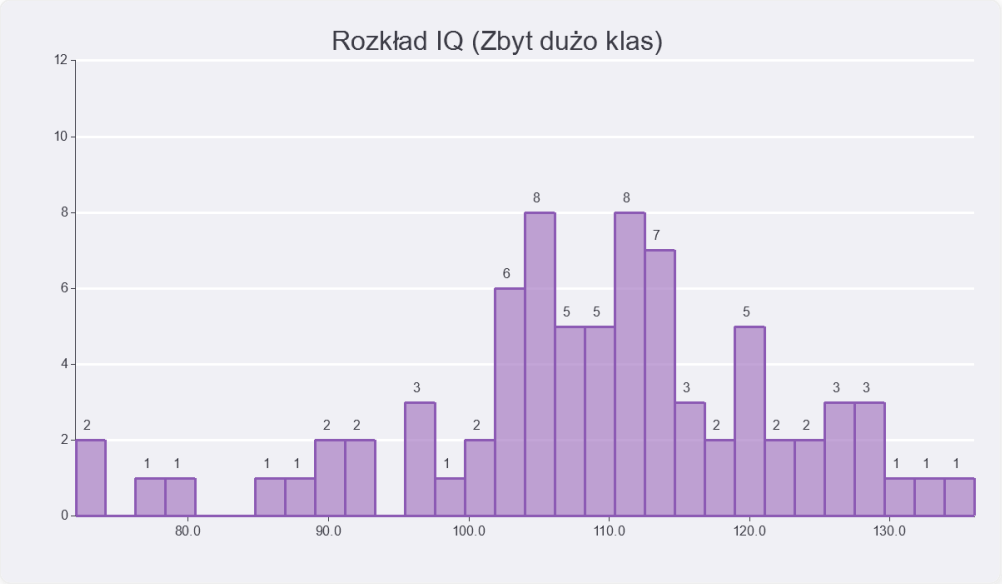


*Rozkład IQ (Zbyt dużo klas)*

> **Wniosek:**
> *Wybór liczby klas ma istotny wpływ na interpretację histogramu. **Zbyt mała liczba klas** nadmiernie upraszcza obraz danych, natomiast **zbyt duża** eksponuje przypadkowy szum i utrudnia odczytanie ogólnych tendencji. Spośród przedstawionych wariantów najbardziej użyteczny jest histogram z liczbą klas wyznaczoną według **reguły Sturgesa**, ponieważ najlepiej zachowuje równowagę między przejrzystością wykresu a dokładnością odwzorowania rozkładu danych.*

## Struktura zarobków mieszkańców USA w roku 2000 (Zad. 2a)

Badana próba zawiera **55899** obserwacji. Analizie poddano roczne zarobki respondentów w **dolarach amerykańskich**.

| Statystyka | Wartość |
|---|---|
| Średnia | 37864.61 |
| Mediana | 29717.00 |
| Minimum | -24998.00 |
| Maksimum | 425510.00 |
| Q1 | 17000.00 |
| Q3 | 46505.00 |
| Wariancja | 1307402975.22 |
| Odchylenie std. | 36158.03 |
| CV (%) | 95.49 |

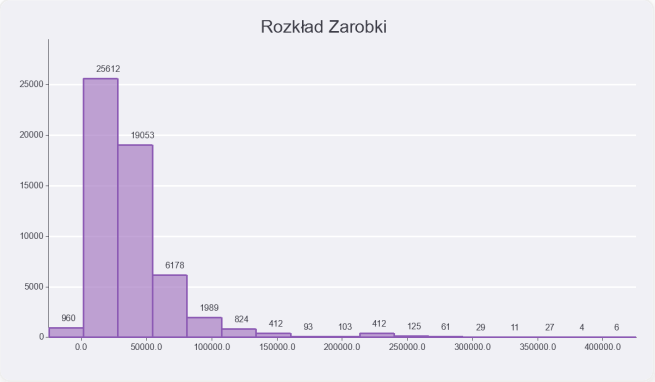


*Rozkład Zarobki*

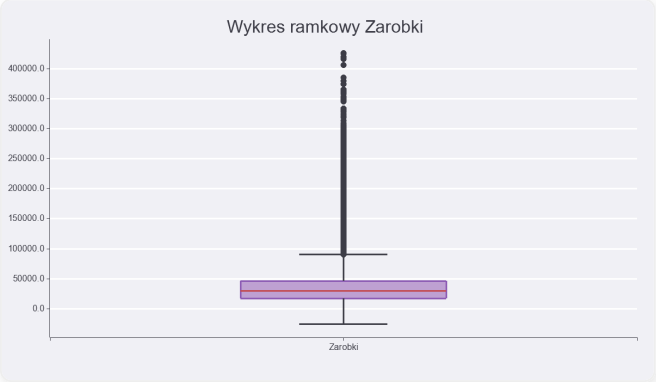


*Wykres ramkowy Zarobki*

**Wniosek:**
*Rozkład zarobków ma charakter **asymetryczny prawostronnie**, czyli **skośny prawostronnie**, co oznacza, że większość osób osiąga relatywnie niższe dochody, natomiast niewielka grupa uzyskuje bardzo wysokie zarobki. W konsekwencji **średnia jest większa od mediany**, co wskazuje na wpływ wysokich wartości odstających. Histogram ujawnia koncentrację obserwacji w dolnych przedziałach oraz **długi ogon po stronie wyższych dochodów**. W danych mogą występować również **ujemne wartości dochodów**, które mogą wynikać np. ze strat działalności gospodarczej lub specyfiki sposobu raportowania dochodów.*

## Porównanie zarobków w zależności od poziomu wykształcenia (Zad. 2b)

W tej części porównano poziom zarobków w **sześciu grupach wykształcenia**: od wykształcenia podstawowego do wyższego magisterskiego.

| Poziom wykształcenia | Średnia | Mediana | Minimum | Maksimum | Q1 | Q3 | Odch. std. | CV |
|---|---|---|---|---|---|---|---|---|
| Podstawowe | 18979.58 | 15765.00 | -9999.00 | 362302.00 | 10400.00 | 23835.00 | 17137.76 | 90.30% |
| Niepełne średnie | 21037.41 | 17011.00 | -9999.00 | 362302.00 | 10500.00 | 27000.00 | 19449.56 | 92.45% |
| Średnie | 28646.15 | 24428.00 | -9999.00 | 425510.00 | 15000.00 | 36256.00 | 23905.37 | 83.45% |
| Niepełne wyższe | 34660.74 | 29500.00 | -9999.00 | 419304.00 | 18006.50 | 43511.50 | 28429.47 | 82.02% |
| Wyższe (licencjat) | 49916.61 | 40072.00 | -9999.00 | 424770.00 | 25841.00 | 61250.00 | 41548.38 | 83.24% |
| Wyższe (magister) | 70727.34 | 55350.00 | -24998.00 | 415928.00 | 36022.50 | 83522.00 | 56859.55 | 80.39% |

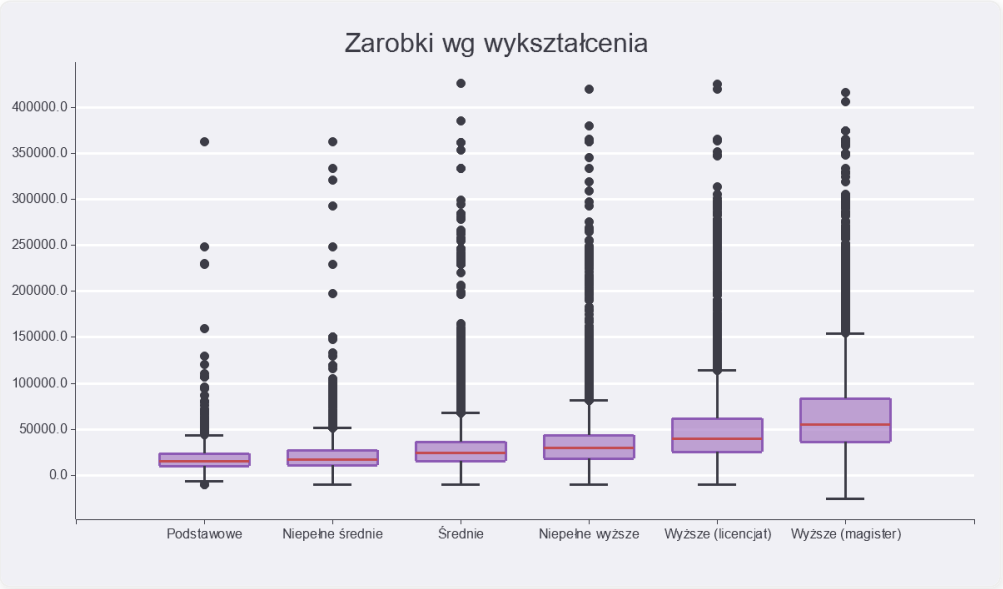


*Zarobki wg wykształcenia*

> **Wniosek:**
> *Zarobki wykazują **wyraźną zależność od poziomu wykształcenia**. Wraz ze wzrostem poziomu edukacji rosną zarówno **średnie**, jak i **mediany** dochodów. Osoby z wykształceniem wyższym osiągają istotnie wyższe dochody niż osoby z niższym poziomem wykształcenia. Jednocześnie w każdej grupie widoczne jest*

> ***znaczne zróżnicowanie***, *co oznacza, że wykształcenie nie jest jedynym czynnikiem wpływającym na poziom zarobków. W grupach o wyższym wykształceniu częściej występują również* ***wartości ekstremalne***, *co wskazuje na większe możliwości osiągania bardzo wysokich dochodów.*

# Porównanie zarobków kobiet i mężczyzn (Zad. 2c)

## Mężczyźni

| Statystyka | Wartość |
|---|---|
| Średnia | 46489.47 |
| Mediana | 36000.00 |
| Minimum | -24998.00 |
| Maksimum | 425510.00 |
| Q1 | 22146.00 |
| Q3 | 55853.00 |
| Wariancja | 1762121910.83 |
| Odchylenie std. | 41977.64 |
| CV (%) | 90.29 |

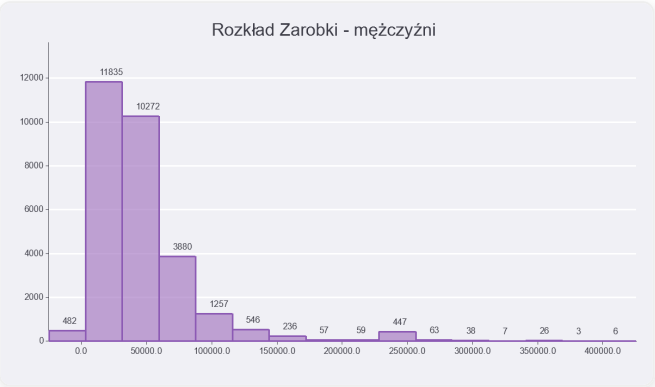


*Rozkład Zarobki - mężczyźni*

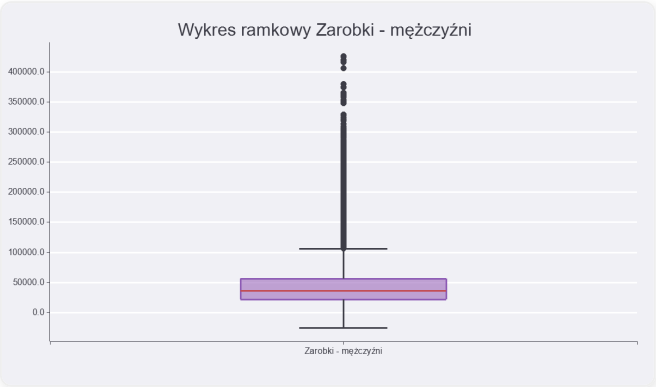


*Wykres ramkowy Zarobki - mężczyźni*

## Kobiety

| Statystyka | Wartość |
|---|---|
| Średnia | 28422.35 |
| Mediana | 23012.00 |
| Minimum | -9999.00 |
| Maksimum | 385068.00 |
| Q1 | 13004.00 |
| Q3 | 36200.00 |
| Wariancja | 639035925.62 |
| Odchylenie std. | 25279.16 |
| CV (%) | 88.94 |

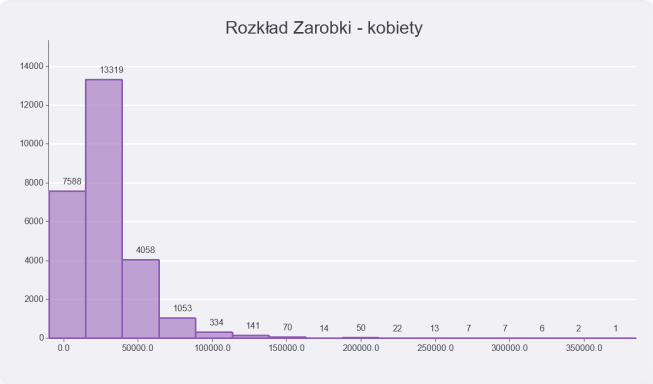


*Rozkład Zarobki - kobiety*

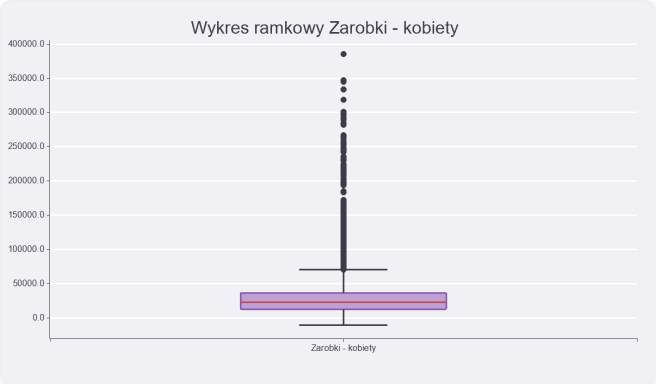


*Wykres ramkowy Zarobki - kobiety*

## Wykres porównawczy

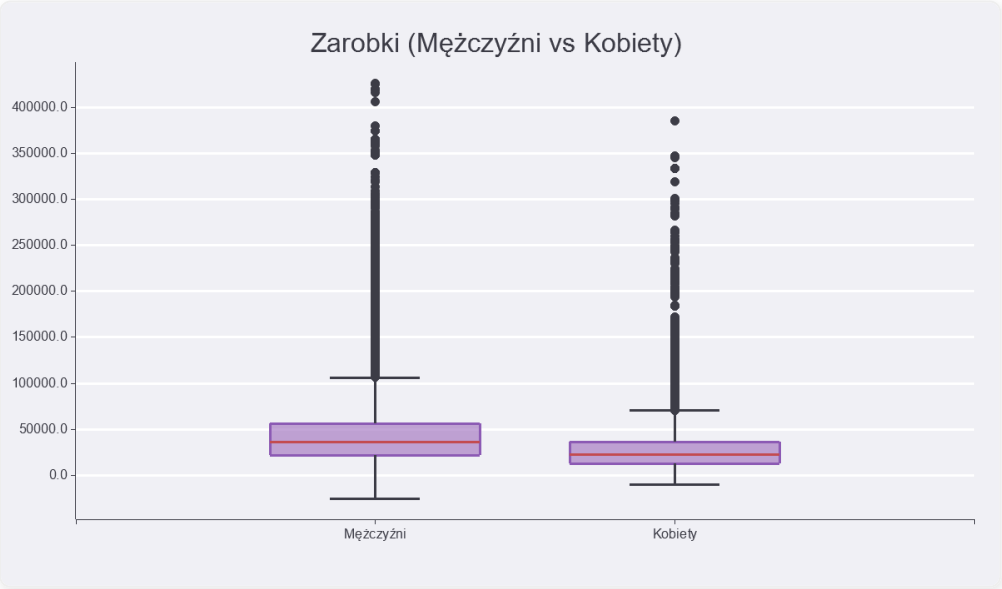


*Zarobki (Mężczyźni vs Kobiety)*

**Wniosek:**
*Analiza danych wskazuje na różnice w poziomie zarobków między **mężczyznami** a **kobietami**. Mężczyźni osiągają wyższe wartości średnie i mediany (średnia: **46489.47**, mediana: **36000.00**) niż kobiety (średnia: **28422.35**, mediana: **23012.00**). Jednak na podstawie tych danych nie można jednoznacznie stwierdzić istnienia **związku przyczynowego**. Różnice te mogą wynikać z wielu czynników, takich jak **wykształcenie**, **sektor zatrudnienia** czy **struktura rynku pracy**. W związku z tym obserwujemy jedynie **korelację**, a nie dowód bezpośredniego wpływu płci na poziom dochodów.*

## Przeciętny zarobek mieszkańców USA w roku 2000 (Zad. 2d)

W celu wyznaczenia „**przeciętnego zarobku**" można rozważyć różne miary tendencji centralnej. Najczęściej stosowane są **średnia arytmetyczna** oraz **mediana**.

| Miara | Wartość |
|---|---|
| Średnia | 37864.61 |
| Mediana | 29717.00 |

> **Wniosek:**
> *Ze względu na **silną asymetrię rozkładu zarobków** oraz obecność **wartości odstających**, średnia arytmetyczna nie jest najlepszą miarą „przeciętnego" dochodu. Znacznie lepszą miarą jest **mediana**, ponieważ jest odporna na wpływ skrajnych wartości. Mediana lepiej oddaje **typowy poziom dochodu większości populacji**, podczas gdy średnia może być zawyżona przez niewielką grupę osób o bardzo wysokich zarobkach.*